

基于 MindSpore 的加州房价预测系统 实验报告

一、实验目的

- 1. 掌握华为 MindSpore 深度学习框架的基本使用方法
- 2. 理解多层感知机（MLP）与自注意力机制的结合方式
- 3. 完成从数据预处理、模型构建、训练评估到可视化部署的完整机器学习流程
- 4. 体验华为云 ModelArts 平台的训练环境及昇腾（Ascend）算力
- 5. 实现训练与推理分离的架构设计，验证模型的跨平台部署能力

二、实验环境

项目	配置
训练平台	华为云 ModelArts（Notebook 环境）
深度学习框架	MindSpore 2.4.10
硬件加速	Ascend 910 / CPU（自动检测回退）
数据集	sklearn.datasets.fetch_california_housing
编程语言	Python 3.10
前端框架	Streamlit 1.59.2 / Flask
推理部署	香橙派（Orange Pi）嵌入式设备

三、数据集介绍

本实验采用加州房价数据集（California Housing Dataset），该数据集来源于 1990 年加州人口普查数据，包含 20,640 条样本，每条样本有 8 个特征和 1 个目标变量。

3.1 特征说明

特征名	含义	数据类型
MedInc	街区收入中位数	连续值
HouseAge	房屋房龄中位数	连续值
AveRooms	平均房间数	连续值
AveBedrooms	平均卧室数	连续值
Population	街区人口	连续值
AveOccup	平均入住人数	连续值
Latitude	纬度	连续值
Longitude	经度	连续值

3.2 目标变量

- **MedHouseVal**: 街区房屋价值中位数，单位为十万美元

3.3 数据预处理

1. **数据集划分**: 训练集 80% (16,512 条) , 测试集 20% (4,128 条) , 随机种子 42
2. **标准化**: 使用 StandardScaler 对特征进行 Z-score 标准化, 消除量纲差异
3. **Scaler 参数保存**: 将 mean 和 scale 保存为 JSON 格式, 供推理端复用

四、模型设计

4.1 模型架构: MLPAttention

本实验设计了一种带自注意力机制的多层感知机 (MLPAttention) , 整体结构分为三个模块:



4.2 关键设计说明

编码器: 两层全连接网络将 8 维输入映射到 128 维隐藏空间, ReLU 激活引入非线性, Dropout 防止过拟合。

注意力模块：采用单 Token 简化版自注意力机制。对编码特征分别做 Q/K/V 线性投影，通过 Sigmoid 门控 $\sigma(Q \odot K)V$ 实现特征间的自适应加权，增强重要特征的表达能力。

融合层：将原始编码特征与注意力输出拼接（256 维），再经两层全连接网络回归到 1 维输出。

4.3 MindSpore 实现要点

- 使用 `nn.Cell` 定义网络（对应 PyTorch 的 `nn.Module`）
- 前向传播在 `construct` 方法中实现（对应 `forward`）
- 使用 `nn.Dense` 定义全连接层（对应 `nn.Linear`）
- 权重导出为 numpy JSON 格式，实现与 MindSpore 解耦的纯 numpy 推理

五、训练过程

5.1 训练配置

超参数	值
优化器	Adam
学习率	0.001
批大小	32
训练轮数	200
Dropout 概率	0.2
隐藏层维度	128
损失函数	MSE Loss
随机种子	42

5.2 训练平台

训练在华为云 ModelArts Notebook 上完成，脚本自动检测设备类型：

- 优先使用 Ascend 910 NPU 加速
- 检测不到 Ascend 时自动回退 CPU

5.3 训练回调

- **LossMonitor**：实时监控训练损失
- **TimeMonitor**：记录每步耗时
- **ModelCheckpoint**：每 epoch 保存模型检查点，最多保留 5 个

六、实验结果

6.1 评估指标

在测试集（4,128 条样本）上的评估结果：

指标	值	含义
MSE	0.2776	均方误差，预测值与真实值差值的平方均值
RMSE	0.5269	均方根误差，与目标变量同量纲（十万美元）
MAE	0.3426	平均绝对误差，平均预测偏差约 3.4 万美元

6.2 结果分析

- RMSE = 0.5269（十万美元） $\approx$ 5.27 万美元，说明模型预测值平均偏离真实值约 5 万美元
- MAE = 0.3426（十万美元） $\approx$ 3.43 万美元，中位数偏差更小
- 加州房价数据本身存在较大方差（房价范围 0.15~5.0 十万美元），该误差水平在可接受范围内

6.3 特征重要性分析

通过扰动法（Permutation Importance）计算各特征对预测结果的影响：

1. 对测试集样本做基准预测
2. 逐一打乱每个特征的值，重新预测
3. 计算预测变化的平均绝对值作为特征重要性

实验结果表明 **MedInc（收入中位数）** 是最重要的预测特征，这与经济学直觉一致——收入水平是决定房价的核心因素。其次是地理位置（Latitude/Longitude）和房屋属性（AveRooms/HouseAge）。

6.4 数据集分析

- **房价分布**：呈右偏分布，大部分街区房价集中在 1~3 十万美元区间
- **特征相关性**：MedInc 与房价呈强正相关（ $r \approx 0.7$ ），Latitude 与房价呈中等负相关

七、系统部署

7.1 训练-推理分离架构

本实验采用训练与推理分离的设计：

阶段	环境	依赖
训练	ModelArts（Ascend/CPU）	MindSpore + 全部依赖
推理	任意 Python 环境	仅 numpy（纯 numpy 实现）

训练完成后导出三个 JSON 文件：

- `weights.json`：模型权重（约 2.1 MB）
- `scaler_params.json`：标准化参数
- `metrics.json`：评估指标

推理端无需安装 MindSpore，用纯 numpy 复现前向传播，实现跨平台部署。

7.2 可视化前端

提供两种 Web 界面：

1. **Streamlit 完整版** (`app.py`)：特征滑块、预测结果、评估指标、特征重要性图表、数据集概览
2. **Flask 轻量版** (`web_server.py`)：适合香橙派等嵌入式设备，资源占用低

7.3 香橙派部署

将模型文件传输到香橙派，安装 `numpy` 和 `flask` 后运行 `web_server.py`，即可通过局域网浏览器访问推理服务。模型推理耗时仅数毫秒，完全满足实时交互需求。

八、实验总结

8.1 主要成果

1. 成功在华为云 ModelArts 平台完成模型训练，验证了 MindSpore 框架的可用性
2. 设计了 MLPAttention 模型，将自注意力机制引入房价预测任务
3. 实现了训练-推理分离架构，推理端纯 `numpy` 实现，不依赖 MindSpore
4. 完成从云端训练到边缘设备（香橙派）部署的完整链路

8.2 技术亮点

- **MindSpore 原生开发**：使用 `nn.Cell`、`construct`、`nn.Dense` 等 MindSpore 特有 API
- **Ascend 自动检测**：训练脚本自动适配 Ascend NPU 或 CPU 环境
- **纯 numpy 推理**：权重以 JSON 格式导出，推理代码与框架解耦
- **跨平台部署**：同一模型可在云端（ModelArts）、PC（Streamlit）、嵌入式设备（香橙派）上运行

8.3 改进方向

1. 增加更多网络结构对比实验（如纯 MLP、CNN、Transformer）
2. 引入学习率调度策略和早停机制
3. 使用交叉验证评估模型稳定性
4. 优化香橙派部署，加入模型量化以进一步降低推理延迟